

大模型微调技术详解（一）：参数高效微调

在大模型时代，完全微调所有参数的成本极高。参数高效微调（PEFT）方法应运而生。

1. LoRA (Low-Rank Adaptation)

LoRA

通过在原始权重矩阵旁路添加低秩分解矩阵来近似参数更新。它仅训练极少量参数（通常小于1%），却能达到接近全参数微调的效果。特别适合在单卡 GPU 上微调 7B 以上的模型。

2. Adapter

在Transformer层之间插入小型适配器模块。虽然参数比LoRA略多，但模块化程度高，易于在不同任务间切换。

3. Prefix Tuning

在输入序列前添加可学习的虚拟 token，只优化这些前缀向量。参数极少，但效果依赖于任务特性。

参数高效微调的核心优势：降低显存占用，防止灾难性遗忘，方便多任务部署。